Recuperación de Información
Grado en Ingeniería Informática
Universidad de Zaragoza

Práctica 3: **Evaluación de sistemas de recuperación de información**

1. Introducción

El objetivo de esta sesión de prácticas es familiarizarse con la evaluación de sistemas de recuperación de información a través de distintas medidas que se pueden obtener cuando se dispone de un banco de pruebas consistente en un conjunto de necesidades de información, y las valoraciones (juicios de relevancia) de los documentos de la colección respecto a esas necesidades.

En primer lugar, la sección 2 describe un conjunto de actividades prácticas orientadas al desarrollo de un programa de evaluación que permite obtener varias medidas de evaluación a partir de los resultados obtenidos por un sistema de recuperación de información para un conjunto de necesidades de información y teniendo disponibles los juicios de relevancia para la colección de esas necesidades.

Una vez finalizada estas actividades introductorias, en la sección 3 se propone aplicar este programa de evaluación al sistema de recuperación que se desarrolló durante la segunda sesión de prácticas para realizar búsquedas sobre la colección de trabajos académicos y tesis doctorales del repositorio digital Zaguan de la Universidad de Zaragoza.

2. Actividades introductorias

2.1. Desarrollo de un programa de evaluación

El objetivo de esta actividad es construir un programa para extraer algunas de las medidas de evaluación de un sistema de recuperación de información que se han visto en las clases de teoría para el tema de Evaluación de Motores de Búsqueda.

Asumiendo que se ha elegido «`evaluation.py`» como nombre del script que contiene el programa principal, se debería poder ejecutar desde una terminal (o línea de comandos) con la siguiente sintaxis para los 3 argumentos de entrada que debe admitir:

Distribuido bajo licencia CC BY-NC-SA. (© Profesorado del DIIS)
`https://creativecommons.org/licenses/by-nc-sa/4.0/deed.es`

```
(.venv) $ python3 evaluation.py -qrels <qrelsFileName> -results <
    ↪ resultsFileName> -output <outputFileName>
```

El argumento *-qrels <qrelsFileName>* permite indicar la ruta del fichero de texto que contiene los juicios de relevancia de una colección de documentos para una o varias necesidades de información. En el fichero «`qrels.txt`» disponible en Moodle se puede ver un ejemplo. Cada línea del fichero de texto contiene tres valores separados por tabuladores:

```
INFORMATION_NEED      DOCUMENT_ID      RELEVANCY
1   1   1
1   2   1
...
2   1   1
2   2   0
```

donde:

- INFORMATION_NEED es el identificador de la necesidad de información.
- DOCUMENT_ID es el identificador de un documento en la colección.
- RELEVANCY es el valor binario del juicio de relevancia: 0 significa no relevante, y 1 significa relevante.

Se hace notar que el orden de los documentos (líneas) en este tipo de ficheros no es indicativo de ningún ranking de relevancia. Solo se proporciona una indicación de relevancia (1) o no relevancia (0).

El argumento *-results <resultsFileName>* permite indicar la ruta del fichero de texto que contiene los documentos que ha recuperado un sistema de recuperación de información para una o varias necesidades de información. En el fichero«`results.txt`» disponible en Moodle se puede ver un ejemplo. Cada línea del fichero de texto contiene dos valores-separados por tabuladores:

```
INFORMATION_NEED      DOCUMENT_ID
1   1
1   2
...
2   1
2   2
```

donde:

- INFORMATION_NEED es el identificador de la necesidad de información.

© CC BY-NC-SA 4.0 Profesorado del DIIS (Universidad de Zaragoza, España)

- DOCUMENT_ID es el identificador de un documento en la colección.

Se hace notar que en este fichero de resultados sí importa el orden de las líneas por cada necesidad de información, ya que este orden indica el orden de relevancia decreciente de cada documento. También se debe tener en cuenta que puede haber documentos que aparezcan en un fichero de resultados, pero no en un fichero con juicios de relevancia. Esto solamente significa que los jueces (evaluadores humanos) no juzgaron la colección entera de documentos. Los documentos que no aparecen en un fichero de juicios de relevanciase consideran no relevantes.

El argumento *-output <outputFileName>* permite indicar la ruta del fichero de texto que se generará con las medidas de evaluación. Las medidas a generar por cada necesidad de información serán: la precisión (*precision*); la exhaustividad (*recall*); la medida F_1 balanceada con $\beta = 1$; la precisión a 10 (*prec@10*); la precisión promedio (*average_precision*) que promedia el valor de la precisión para los k documentos *top* cada vez que se recupera un documento relevante; los puntos exhaustividad-precisión (*recall_precision*) que permitirían generar la curva de precisión-exhaustividad; y los puntos exhaustividad-precisión interpolados (*interpolated_recall_precision*) que permitirían generar la curva de precisión-exhaustividad interpolada sobre 11 puntos de exhaustividad (desde 0.0 a 1.0). Asimismo, se mostrarán las siguientes medidas globales: la precisión global (*precision*); la exhaustividad global (*recall*); la medida F_1 global (calculada en base a la precisión global y la exhaustividad global); la precisión a 10 global (*prec@10*); la medida MAP; y los puntos exhaustividad-precisión interpolados promedio (*interpolated_recall_precision*) que permitirían generar la curva de precisión-exhaustividad interpolada sobre 11 puntos de exhaustividad (desde 0.0 a 1.0).

Además, para facilitar el cálculo de algunas medidas en casos problemáticos se tendrá en cuenta lo siguiente:

- La medida "precisión a 10 (*prec@10*)" para una consulta de un sistema que devuelve menos de 10 resultados será la división entre 10 del número de documentos relevantes recuperados.
- La medida "precisión promedio (*average_precision*)" de una consulta que no devuelve ningún resultado relevante será por defecto 0.
- A la hora de calcular los puntos exhaustividad-precisión interpolados para una consulta, si hay algún nivel de exhaustividad para el cual no es posible calcular su precisión, se asumirá que por defecto su precisión es 0. Esta decisión permitirá que las curvas de precisión-exhaustividad globales alcancen un nivel 1.0 de exhaustividad.

Si se ejecutase el programa de evaluación para los ficheros de ejemplo «`qrels.txt`» y «`results.txt`» se debería generar un fichero con el siguiente formato. Cuando hay más de un valor por línea, se separa con un tabulador para facilitar después su posible procesamiento:

© CC BY-NC-SA 4.0 Profesorado del DIIS (Universidad de Zaragoza, España)

```
INFORMATION_NEED 1
precision 0.300
recall 0.750
F1 0.429
prec@10 0.300
average_precision 0.555
recall_precision
0.125 1.000
0.250 1.000
0.375 0.333
0.500 0.364
0.625 0.333
0.750 0.300
interpolated_recall_precision
0.000 1.000
0.100 1.000
0.200 1.000
0.300 0.364
0.400 0.364
0.500 0.364
0.600 0.333
0.700 0.300
0.800 0.000
0.900 0.000
1.000 0.000

INFORMATION_NEED 2
precision 0.400
recall 1.000
F1 0.571
prec@10 0.400
average_precision 0.600
recall_precision
0.250 1.000
0.500 0.667
0.750 0.333
1.000 0.400
interpolated_recall_precision
0.000 1.000
0.100 1.000
0.200 1.000
0.300 0.667
0.400 0.667
0.500 0.667
0.600 0.400
0.700 0.400
0.800 0.400
0.900 0.400
1.000 0.400
```

© CC BY-NC-SA 4.0 Profesorado del DIIS (Universidad de Zaragoza, España)

```
TOTAL
precision 0.350
recall 0.875
F1 0.500
prec@10 0.350
MAP 0.578
interpolated_recall_precision
0.000 1.000
0.100 1.000
0.200 1.000
0.300 0.515
0.400 0.515
0.500 0.515
0.600 0.367
0.700 0.350
0.800 0.200
0.900 0.200
1.000 0.200
```

Para desarrollar el programa de evaluación, aparte de seguir un análisis y diseño orientado a objeto, se recomienda utilizar estructuras de datos de tipo diccionario (tabla) que permitan establecer una asociación entre una necesidad de información y los juicios de relevancia, los documentos recuperados o las medidas de evaluación.

Una vez desarrollado el programa, verifica si se generan los mismos resultados que los incluidos en esta sección.

2.2. Creación de gráficas para comparar medidas de evaluación

Para facilitar un análisis rápido de las medidas de evaluación, puede ser conveniente generar gráficas sobre las medidas de evaluación obtenidas con el programa de evaluación desarrollado. Entre otras posibilidades, se podrían crear curvas de precisión-exhaustividad, o gráficos de barras para comparar las medidas obtenidas entre distintas necesidades de información (o comparar medidas globales entre distintos sistemas).

Por ejemplo, la figura 1 muestra las curvas de precisión-exhaustividad generadas a partir de los 11 puntos de exhaustividad-precisión interpolados correspondientes a las dos necesidades de información del ejemplo de la sección 2.1. Además, también se incluye la curva promedio (curva *Total*) de las dos necesidades de información a partir de los puntos promedio.

La biblioteca Matplotlib[1] de Python permite construir fácilmente este tipo de gráficas. Por ejemplo, en el siguiente extracto de código se indican los principales pasos para dibujar una curva de precisión-exhaustividad:

© CC BY-NC-SA 4.0 Profesorado del DIIS (Universidad de Zaragoza, España)

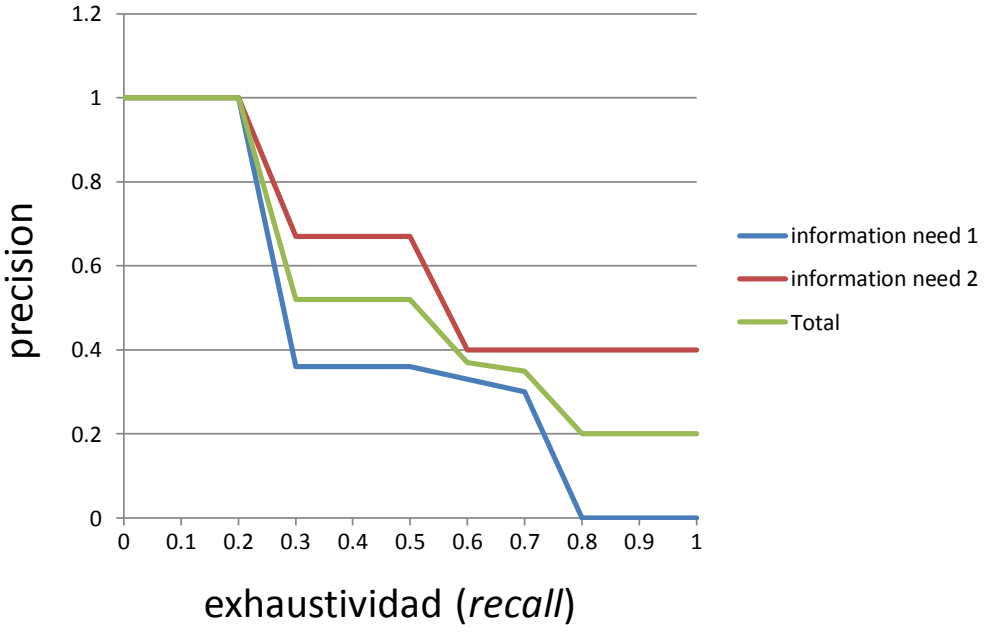


Figura 1: Curva precisión-exhaustividad para los puntos exhaustividad-precisión interpolados incluidos en la sección 2.1

```
import matplotlib.pyplot as plt
import numpy as np

x = np.linspace(0.0, 1.0, 11)
y = np.asarray([1.0,0.9,0.8,0.7,0.6, 0.5, 0.4, 0.3, 0.2, 0.1,
    ↪ 0.0])
fig, ax = plt.subplots()
ax.plot(x, y, label='system a')
ax.set_title('precision-recall curve')
ax.set_xlabel('recall')
ax.set_ylabel('precision')
plt.legend(loc='upper right')
plt.show()
```

3. Actividades evaluables

Para poder realizar la evaluación del sistema de recuperación de información entregado como resultado de la sesión de segunda sesión de prácticas se cuenta con el fichero «`zaguanRels.txt`». Este fichero contiene los juicios de relevancia de la colección de meta-

© CC BY-NC-SA 4.0 Profesorado del DIIS (Universidad de Zaragoza, España)

datos del repositorio Zaguan para las necesidades de información propuestas en el fichero «`necesidadesInformacion.xml`» (ver material de la sesión de prácticas 2).

A continuación se muestran algunos datos estadísticos del proceso de creación del fichero de juicios de relevancia:

- Se han realizado 882 juicios de relevancia de acuerdo a la siguiente distribución: 149 documentos valorables para necesidad de información 105-5; 161 para la 106-4; 118 para la 107-2; 189 para la 109-2; y 265 para la 208-1.
- Cada juicio de relevancia fue realizado por dos jueces. La tabla 1 muestra la proporción de acuerdo *P(A)*, la proporción de acuerdo esperado *P(E)* y la medida Kappa de acuerdo entre jueces.

Nº documentos	Juez 1	Juez 2
120	relevantes	relevantes
645	no relevantes	no relevantes
59	relevantes	no relevantes
58	no relevantes	relevantes

P (A)	0,867
P (no relevante)	0,798
P (relevante)	0,202
P (E)	0,677
Kappa	0,589

Tabla 1: Medida Kappa de acuerdo entre jueces

- Para la valoración final de relevancia se ha considerado que un documento es relevante si cualquiera de los jueces lo ha considerado relevante. En total, 237 documentos fueron considerados relevantes para las 5 necesidades de información.

Los requisitos técnicos del programa de evaluación que se debe desarrollar son los mismos que se especificaron en la sección 2.1. La única diferencia es que ahora **solo se evaluarán un máximo de 45 resultados por necesidad de información** para facilitar la comparación de medidas de evaluación entre los sistemas desarrollados por los distintos equipos.

Para verificar la corrección del programa de evaluación que se debe desarrollar, se facilitan dos ficheros de resultados denominados «`resultados_sistema_a.txt`» y «`resultados_sistema_b.txt`», los cuales se obtuvieron por dos sistemas *a* y *b* de características similares al exigido en la sesión de prácticas 2 después de procesar las mismas necesidades de información. En la tabla 2 se muestran las medidas de evaluación que se deberían obtener con vuestro programa de evaluación para esos ficheros de resultados. En la figura 2 también se pueden observar las curvas promedio de precisión-exhaustividad interpolada sobre 11 puntos de los sistemas *a* y *b*.

© CC BY-NC-SA 4.0 Profesorado del DIIS (Universidad de Zaragoza, España)

Medida	a	b
precision	0,378	0,489
recall	0,375	0,484
F1	0,376	0,486
prec@10	0,64	0,76
MAP	0,591	0,705

recall point	a	b
0	0,824	1
0,1	0,671	0,821
0,2	0,601	0,753
0,3	0,479	0,643
0,4	0,414	0,345
0,5	0,2	0,218
0,6	0,1	0,107
0,7	0	0
0,8	0	0
0,9	0	0
1	0	0

Tabla 2: Medidas de evaluación

4. Resultados a entregar

Como resultado de esta sesión de prácticas, uno los miembros de cada equipo subirá los siguientes entregables resultantes de las actividades solicitadas en la sección 3 a través de una tarea disponible en el ADD:

- Un fichero comprimido conteniendo: el código fuente debidamente documentado del programa de evaluación; y un fichero de texto denominado «`traditionalEvaluationResults<NNN>.txt`»[1] con las medidas resultantes de la evaluación del sistema de recuperación entregado en la sesión de prácticas 2. Es decir, se evaluará el fichero de resultados «`equipo<NNN>.txt`» entregado en la sesión de prácticas 2 obtenido al procesar las necesidades de información propuestas. El formato del fichero «`traditionalEvaluationResults<NNN>.txt`» se deberá ajustar al especificado en el ejemplo incluido en la sección 2.1.

- Un pequeño de informe en formato PDF con una extensión aproximada de 2-3 páginas donde se incluirá, al menos, una discusión de los siguientes asuntos:

    1. La capacidad del programa para obtener las medidas esperadas de los sistemas *a* y *b* (tabla 2 y figura 2).

[1] <NNN> se corresponde con el número del equipo.

© CC BY-NC-SA 4.0 Profesorado del DIIS (Universidad de Zaragoza, España)

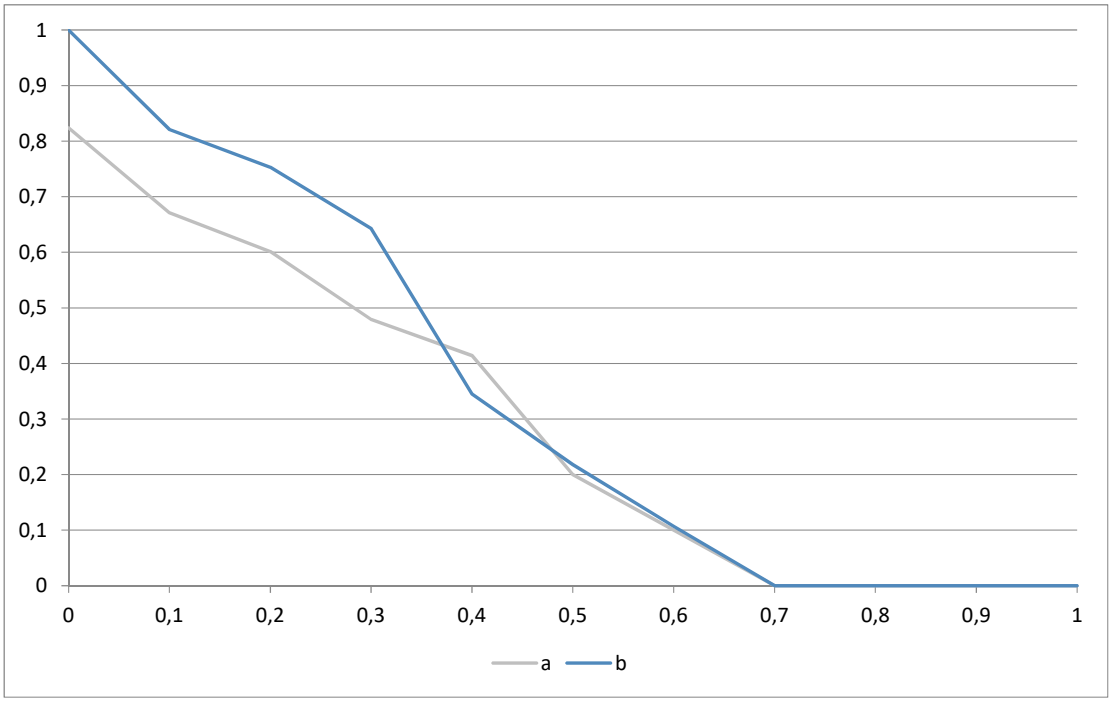


Figura 2: Curvas precisión-exhaustividad interpoladas correspondientes a los puntos mostrados en la tabla 2

2. La comparación de las medidas de vuestro sistema frente a las obtenidas por los sistemas *a* y *b*.

3. La comparación de las medidas de vuestro sistema frente a las obtenidas por los programas de indexación y búsqueda utilizando la librería Gensim de la práctica 1 e idioma español. Se puede modificar ligeramente el programa de búsqueda con Gensim para leer cada necesidad de información del fichero XML, construir el vector consulta del texto completo de cada necesidad de información, y generar un fichero de resultados compatible transformando los nombres de los ficheros en las correspondientes URLs:

```
i = 1
for document_number, score in sorted(enumerate(sims), key=
    ↪ lambda x: x[1], reverse=True):
    if score == 0.0 or i > 100:
        break
    url = 'http://zaguan.unizar.es/record/'+file_paths[
        ↪ document_number].replace('oai_zaguan.unizar.es_'
        ↪ ,'').replace('.xml','')
    file.write(f'{query_identifier}\t{url}\n')
    i += 1
```

4. Una reflexión sobre la medida, o medidas, que se consideran mejores para reflejar la calidad de un sistema de recuperación.

5. ¿Qué decisiones de diseño de tu sistema (campos indexados, analizadores elegidos, modelo de ranking, procesamiento de necesidades de información para la construcción de consultas, ...) justifican las medidas obtenidas? Si lo consideras apropiado, puedes realizar modificaciones en los programas de la práctica 2 y comentar las mejoras obtenidas en las medidas.

La fecha límite para subir estos entregables en el ADD será el día anterior a la siguiente sesión de prácticas de cada equipo.

Referencias

[1] The Matplotlib development team. Matplotlib, Getting started. `https://matplotlib.org/stable/users/getting_started/`, 2024.

© CC BY-NC-SA 4.0 Profesorado del DIIS (Universidad de Zaragoza, España)