RECUPERACIÓN DE INFORMACIÓN
INFORME PRÁCTICA 3

Alba Moriano Plou (901756) y Siddhartha Montoya (896973)

---

1. **La capacidad del programa para obtener las medidas esperadas de los sistemas a y b**

   Para comprobar el correcto funcionamiento del programa de evaluación, se ha ejecutado utilizando los ficheros de resultados proporcionados para los sistemas A y B. El objetivo es verificar que las medidas calculadas por nuestro programa coinciden con las especificadas en el enunciado de la práctica.

   Siendo A y B los valores obtenidos mediante nuestro programa, y A'' y B'' los valores de referencia proporcionados en el enunciado, a continuación se muestran los resultados:

Medida	A	A''	B	B''
precision	0.378	0.378	0.489	0.489
recall	0.375	0.375	0.484	0.484
F1	0.376	0.376	0.486	0.486
prec@10	0.640	0.64	0.760	0.76
MAP	0.591	0.591	0.705	0.705

   Asimismo, se han comparado los valores de precisión interpolada para los distintos niveles de exhaustividad.

interpolated recall precision	A	A''	B	B''
0.0	0.824	0.824	1.000	1
0.1	0.671	0.671	0.821	0.821
0.2	0.601	0.601	0.753	0.753
0.3	0.479	0.479	0.643	0.643
0.4	0.414	0.414	0.345	0.345
0.5	0.200	0.2	0.218	0.218
0.6	0.100	0.1	0.107	0.107
0.7	0.000	0	0.000	0

0.8	0.000	0	0.000	0
0.9	0.000	0	0.000	0
1.0	0.000	0	0.000	0

Como se puede observar, todas las medidas obtenidas coinciden exactamente con a las proporcionadas por el enunciado, tanto para el sistema A como para el sistema B. Esta coincidencia se produce también en los once puntos de precisión interpolada.

Por tanto, podemos concluir que el programa calcula correctamente las medidas de evaluación solicitadas y que su implementación es coherente con los resultados esperados. Esto permite tener confianza en su funcionamiento para evaluar posteriormente nuestro propio sistema.

2. **La comparación de las medidas de vuestro sistema frente a las obtenidas por los sistemas a y b.**

Una vez comprobado el correcto funcionamiento del programa de evaluación, se ha aplicado al sistema desarrollado en la práctica 2. A continuación, se comparan los resultados con los obtenidos por los sistemas A y B:

Medida	P2	A	B
precision	0.289	0.378	0.489
recall	0.267	0.375	0.484
F1	0.277	0.376	0.486
prec@10	0.620	0.640	0.760
MAP	0.731	0.591	0.705

En primer lugar, se puede observar que nuestro sistema obtiene valores inferiores a los sistemas A y B en precisión, recall y F1. Esto indica que recupera una proporción menor de documentos relevantes y que tiene un rendimiento inferior en cuanto a cantidad de documentos relevantes recuperados respecto al conjunto total de documentos relevantes.

En cuanto a la precisión a 10, nuestro sistema obtiene un valor bastante cercano al del sistema A, aunque inferior al del sistema B. Esto indica que nuestro sistema consigue situar una cantidad relativamente elevada de documentos relevantes entre los 10 primeros.

Sin embargo, nuestro sistema destaca especialmente en el resultado del MAP, donde obtiene un valor de 0.731, superior tanto al sistema A como al sistema B. Esto significa que, a pesar de recuperar menos documentos relevantes, nuestro sistema

consigue posicionar los documentos relevantes de una forma especialmente favorable dentro de los resultados recuperados.

También se han comparado los valores de la precisión interpolada.

interpolated recall precision	P2	A	B
0.0	1.000	0.824	1.000
0.1	0.741	0.671	0.821
0.2	0.479	0.601	0.753
0.3	0.247	0.479	0.643
0.4	0.000	0.414	0.345
0.5	0.000	0.200	0.218
0.6	0.000	0.100	0.107
0.7	0.000	0.000	0.000
0.8	0.000	0.000	0.000
0.9	0.000	0.000	0.000
1.0	0.000	0.000	0.000

A partir de estos datos, se observa que nuestro sistema presenta una precisión interpolada superior a la del sistema A en los dos primeros niveles de exhaustividad, pero comienza a ser inferior a partir del nivel 0.2. Respecto al sistema B, únicamente iguala su precisión en el primer punto, siendo inferior en los siguientes niveles hasta alcanzar una precisión de cero a partir de un recall de 0.4.

Esto refleja que nuestro sistema consigue buenos resultados cuando se consideran los primeros documentos recuperados, pero pierde capacidad para recuperar más documentos relevantes conforme aumenta el nivel de exhaustividad.

En conclusión, aunque nuestro sistema no alcanza los resultados de precisión, recall y F1 de los sistemas A y B, destaca especialmente en MAP. Esto sugiere que su principal fortaleza se encuentra en el orden en el que presenta los documentos relevantes.

3. **La comparación de las medidas de vuestro sistema frente a las obtenidas por los programas de indexación y búsqueda utilizando la librería Gensim de la práctica 1 e idioma español.**

A continuación se compara el sistema desarrollado en la práctica 2 con el sistema implementado en la práctica 1 que utiliza la librería Gensim:

Medida	P2	P1 (Gensim)
precision	0.289	0.298
recall	0.267	0.269
F1	0.277	0.283
prec@10	0.620	0.500
MAP	0.731	0.540

Al comparar las medidas, observamos que el sistema de la práctica 1 obtiene resultados muy ligeramente superiores en precisión, recall y F1. Las diferencias son pequeñas, por lo que ambos sistemas presentan un comportamiento bastante similar en cuanto a la proporción de documentos relevantes recuperados.

Sin embargo existen diferencias importantes en las medidas relacionadas con el orden de los resultados. Nuestro sistema de la práctica 2 muestra una mejora considerable en la precisión a 10 (0.62 frente a 0.5) y esto significa que consigue devolver más documentos relevantes entre los diez resultados.

La diferencia también es notable en MAP, donde P2 alcanza un valor de 0.731 frente a 0.540. Por tanto, aunque el sistema Gensim consigue recuperar ligeramente más documentos relevantes, nuestro sistema ordena mejor, situando documentos relevantes en posiciones más altas del ranking.

interpolated recall precision	P2	P1 (Gensin)
0.0	1.000	0.824
0.1	0.741	0.493
0.2	0.479	0.429
0.3	0.247	0.302
0.4	0.000	0.130
0.5	0.000	0.000
0.6	0.000	0.000
0.7	0.000	0.000
0.8	0.000	0.000
0.9	0.000	0.000
1.0	0.000	0.000

Estos resultados de precisión interpolada permiten apreciar que P2 ofrece una mejor ordenación inicial de documentos relevantes, mientras que P1 mantiene cierta capacidad para recuperar documentos relevantes a niveles de exhaustividad más elevados.

4. **Una reflexión sobre la medida, o medidas, que se consideran mejores para reflejar la calidad de un sistema de recuperación.**

   Consideramos que no existe una única medida que permita evaluar completamente la calidad de un sistema de recuperación, ya que cada una analiza un aspecto diferente.

   La **precisión** y el **recall** son fundamentales: la primera indica qué proporción de los documentos recuperados son relevantes, mientras que la segunda mide cuántos de los documentos relevantes existentes ha conseguido encontrar el sistema. Sin embargo, pueden entrar en conflicto: un sistema puede obtener una precisión elevada recuperando pocos documentos, o conseguir un recall elevado devolviendo muchos documentos.

   Para combinar ambas medidas se utiliza **F1**, que representa su media armónica. Consideramos que es una buena medida general porque tiene en cuenta tanto la precisión como el recall y penaliza un desequilibrio importante entre ambas. No obstante, no tiene en cuenta el orden en el que aparecen los documentos recuperados, algo que resulta especialmente importante en un motor de búsqueda.

   Por otro lado, consideramos que **Prec@10** y **MAP** son especialmente interesantes, ya que tienen en cuenta la posición de los documentos relevantes en los resultados. Prec@10 mide la relevancia de los diez primeros documentos, mientras que MAP evalúa cómo de bien están ordenados los documentos relevantes a lo largo de los resultados.

   Por tanto, consideramos que MAP y Prec@10 son especialmente representativas de la calidad de un buscador, ya que el orden en el que se muestran los resultados, en este caso, es algo muy importante a tener en cuenta, pues los usuarios suelen consultar solo los primeros resultados. De todos modos, estos resultados deben complementarse con precisión, recall y F1 para obtener una evaluación más completa del sistema.

5. **¿Qué decisiones de diseño de tu sistema (campos indexados, analizadores elegidos, modelo de ranking, procesamiento de necesidades de información para la construcción de consultas, ...) justifican las medidas obtenidas? Si lo consideras apropiado, puedes realizar modificaciones en los programas de la práctica 2 y comentar las mejoras obtenidas en las medidas.**

   El sistema utiliza un índice basado en los campos principales de los documentos y aplica tokenización, eliminación de palabras vacías y stemming en español. Además, emplea spaCy y reglas específicas para identificar información como personas,

organizaciones, años, idiomas y tipos de trabajo. Para ordenar los resultados utiliza el modelo de puntuación de Whoosh y distintos pesos según el campo, dando más importancia al título y a las materias.

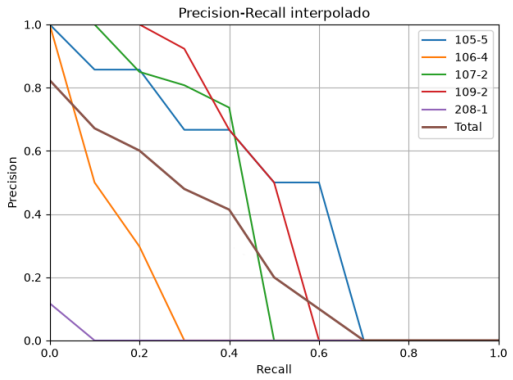
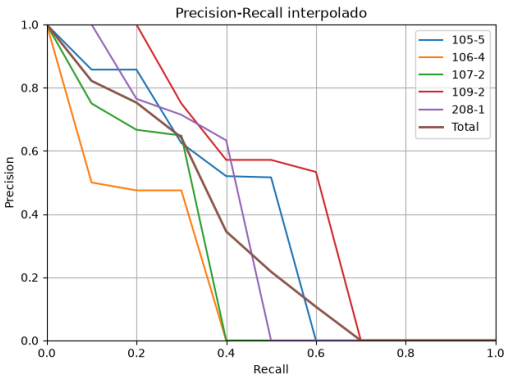
Estas decisiones parecen favorecer especialmente el orden de los documentos relevantes, como reflejan los valores de MAP (0,731) y Prec@10 (0,620), superiores a los de P1 Gensim y los sirenas A y B. Sin embargo, la precisión, el recall y el F1 son ligeramente inferiores. Esto indica que, aunque los documentos relevantes aparecen mejor posicionados, el sistema no recupera necesariamente una mayor cantidad de ellos.

Una posible explicación es que el procesamiento de las consultas, especialmente la eliminación de palabras y la detección de entidades, puede provocar que se pierdan algunos términos relevantes. Asimismo, el uso de operadores OR facilita recuperar más documentos, pero también puede introducir resultados menos relacionados con la necesidad de información.

En conclusión, consideramos que las decisiones de diseño han permitido obtener un sistema que destaca especialmente en la ordenación de los documentos relevantes, aunque todavía existen aspectos mejorables, como el procesamiento de las consultas y el equilibrio entre precisión y exhaustividad. Una posible mejora sería ajustar las ponderaciones de los campos para intentar aumentar la cantidad de documentos relevantes recuperados sin perjudicar su posición en los resultados.

6. Anexo: Gráficas de Interpolated Recall.

Para una mejor visualización de los datos de interpolated recall, se ha implementado en el fichero de evaluación que opcionalmente imprima la gráfica correspondiente. A continuación se muestran los resultados obtenidos:

Sistema A	Sistema B
	

Sistema P1	Sistema P2
